


Основные концепции



Аналитика
Инженерия данных (Data Engineering)

01



Содержание

→ О курсе и зачем он вам

→ Кто такой инженер данных и его роль
в индустрии данных


→ Какими инструментами будем пользоваться

→ Организационные моменты

→ Воркшоп по файловым хранилищам



О курсе





Кирилл Гоменюк

Академический
лид на курсе
Инженерия данных
в магистратуре ЦУ.

Строил платформу
данных в «Т-Банк».



Никита Гирш

Более 5 лет опыта
в data-индустрии.

Руководитель команды
дата-инженеров
в банке «Дом.РФ»



Андрей Лебедев

Разрабатывает
пайплайны
для высоконагруженной
аналитики в розничных
рисках «Сбера».




Борзунов Никита

Создаёт цифровой
фундамент банка
от концепции data-
архитектуры
до перевода бизнеса
на новые технологий.

Инженерия данных

Как превращать данные в ценность


Вы освоите современные инструменты платформ данных — от хранения и обработки до надёжных конвейеров (пайплайнов) и качества данных.



Данные — новая основа бизнеса

Если всё в порядке
с данными

- Более точное принятие решений
- Стабильная работа ML
- Эффективный маркетинг
- Повышение конкурентоспособности
- ...



Данных мало не бывает


1 фотография = 10 Мб

Гипермаркет = 10 Гб в час

Boeing 787 = 500 Гб за полёт


Количество данных, создаваемых в мире (2010–2025)

Данные в зеттабайтах, * — прогноз




Почему это не «ещё один курс»

- У нас есть своя инфраструктура.
- «Живые» источники данных, к которым можно подключаться, как в реальной работе.
- Пройдём полный цикл работы с данными: от источников до витрин и аналитики.
- Делаем акцент на инженерном подходе.
- Полученные навыки можно применять сразу в рабочих задачах.




**Кто такой
инженер
данных**




Инженер данных

- Собирает, хранит и преобразует данные в пригодный для анализа вид.
- Проектирует надёжные потоки данных.
- Отвечает за скорость, качество и доступность данных.
- Работает на стыке инфраструктуры, разработки и аналитики.




Чем занимается инженер данных




ETL-процессы (потоки, пайплайны):

- **E**xtract — сбор, или извлечение;
- **T**ransform — обработка;
- **L**oad — загрузка.



Как работает инженер данных




Роль дата-инженера в индустрии данных



Что должен знать и уметь инженер данных



Инженер данных — это аналитик, разработчик и администратор.




- Хорошо разбираться в базах данных
- Отлично знать SQL
- Владеть несколькими языками программирования (например, Python, Java, Scala)
- Понимать основы распределённых систем
- Знать, что делать с большими данными в Spark, Kafka


Путь от основ к реальным задачам

- Старт курса: роль инженера данных, хранилище S3, инструменты для работы с файлами, введение в ETL.
- Середина курса: Data Lakehouse, стриминг и распределённая обработка данных.
- Завершение курса: витрины в ClickHouse, оптимизация и качество.

Итог: на практике познакомимся с основными задачами инженера данных от получения сырых данных до построения аналитических таблиц.




Какие навыки получим по итогам курса?




Где и как хранить данные?

- Хранилища и форматы: S3, Parquet, Apache Iceberg
- Аналитические базы: ClickHouse



Как загружать и обрабатывать данные?

- Распределённая обработка: Apache Spark (batch)
- Поточковая обработка: Kafka + Spark Streaming
- Оркестрация ETL/ELT: Apache Airflow




Как обеспечивать надёжность потоков и качество данных?


- Оптимизация и производительность
- Data Quality и надёжность пайплайнов

Ожидаемые результаты обучения

- Уверенно подключаетесь к хранилищам и рабочей инфраструктуре.
- Самостоятельно строите и автоматизируете пайплайны данных.
- Разбираетесь в инструментах сбора и обработки данных.
- Готовы выполнять типовые задачи инженера данных уровня junior/middle.



Инструменты



Используемые инструменты



DuckDB



kafka



Greenplum



Объектное
хранилище S3



ClickHouse




Apache
Airflow




PostgreSQL

Учебная платформа данных


Источники




Инструменты
обработки данных



Системы хранения данных




Инструменты разработки
и ad-hoc-аналитики




Учебная платформа данных


Источники



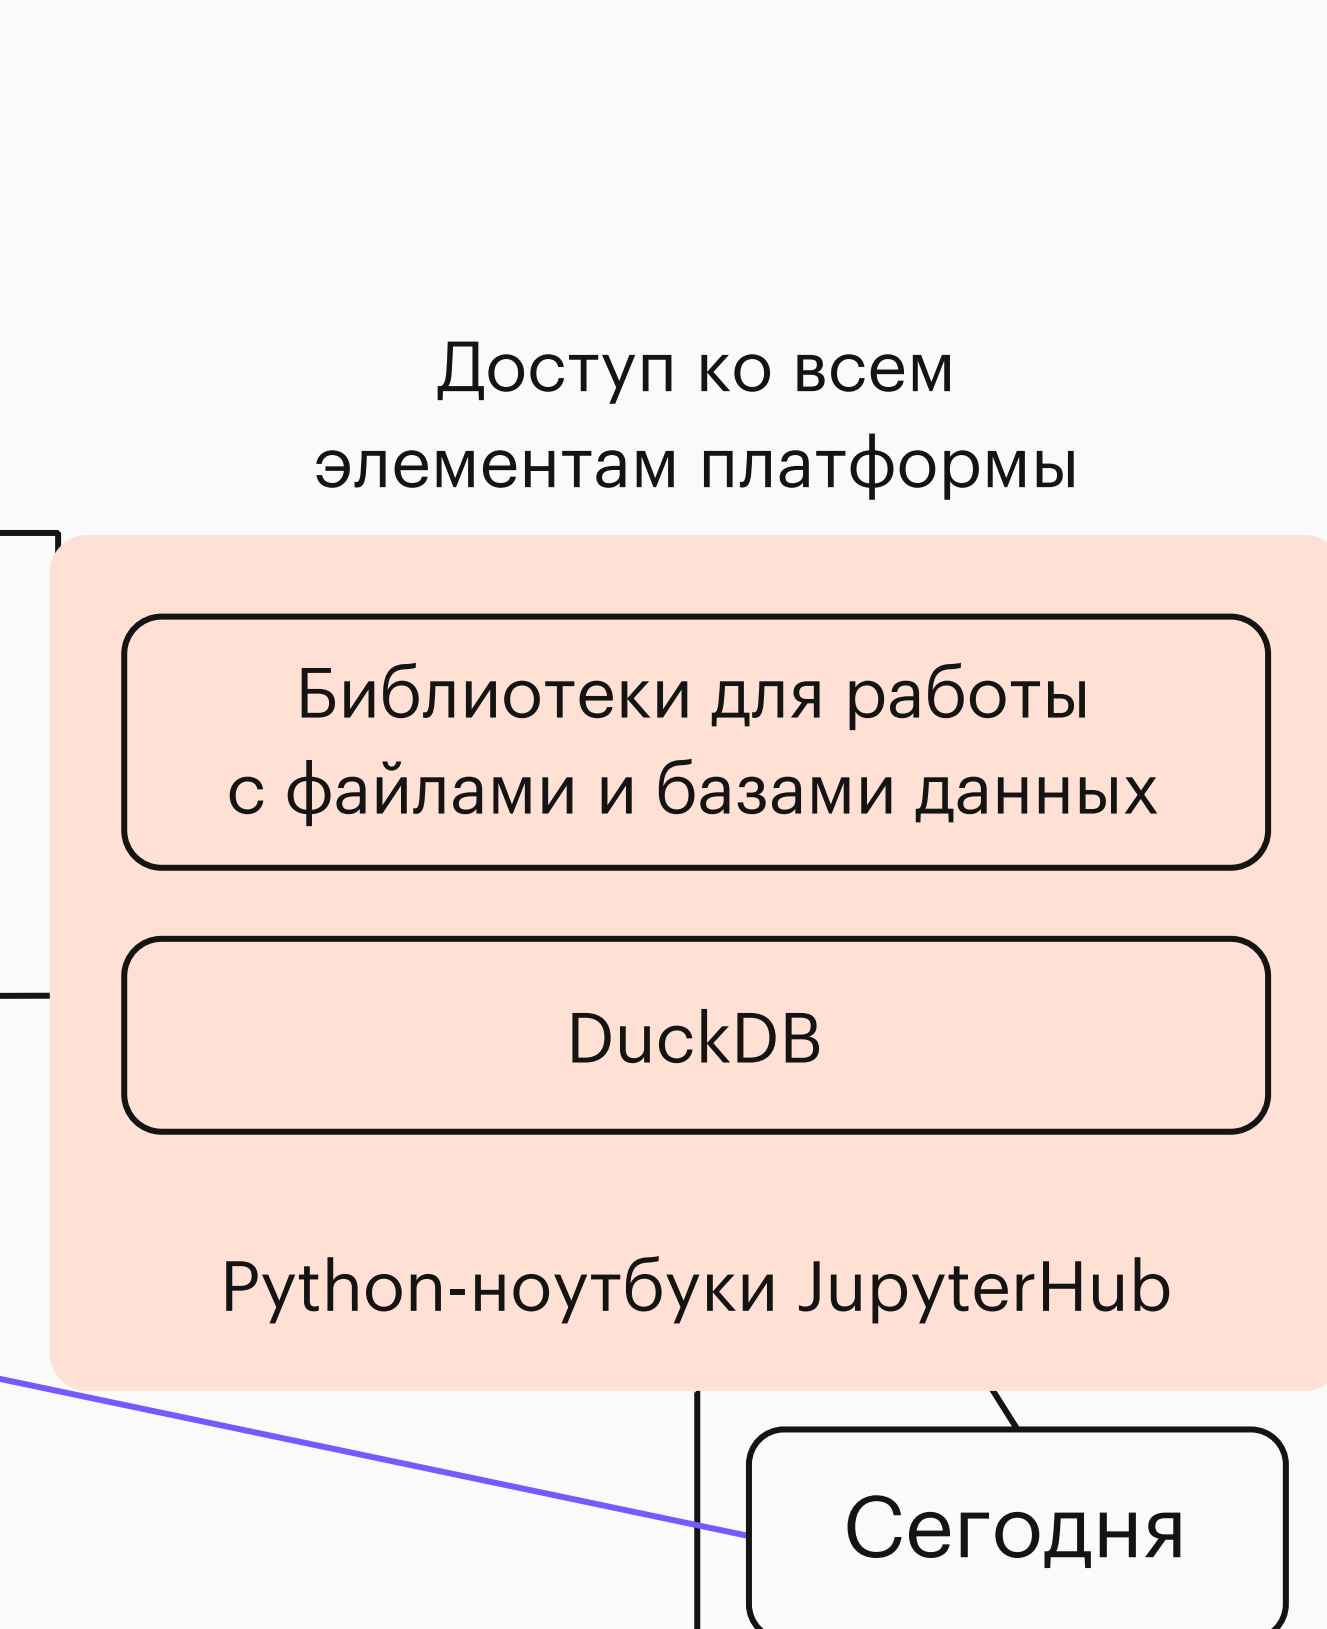
Инструменты
обработки данных




Системы хранения данных





Инструменты разработки
и ad-hoc-аналитики




Организация курса




Тематический план




Файловые хранилища




Автоматизация процессов ETL




Распределённая обработка данных в Spark




Потоковая обработка в Spark и Kafka




Хранение и обработка данных
в кластере ClickHouse



Построение витрин





Оптимизация запросов в Apache Spark




Качество данных


Что будем делать на курсе




Подключаться к S3 и работать с файловыми данными




Создавать и использовать таблицы Apache Iceberg




Писать Python-скрипты для Spark и Kafka




Автоматизировать процессы в Airflow через Python



Писать SQL-запросы в ClickHouse




Встраивать проверки качества данных и мониторинг




Оптимизировать пайплайны и производительность

Учебная нагрузка



- Длительность курса — 14 недель
- 14 лекций + 13 семинаров
- 12 домашних заданий
- 13 мини-КР на семинарах
- Контрольная работа на 9 неделе
- Экзамен

Формат обучения



Система оценивания

Домашняя работа

40%

Контрольная работа (блок)

20%

Экзамен (блок)

30%

Тесты на семинарах

10%

Бонусные баллы
За поиск ошибок и полезные идеи

10%

Вопросы

